



MoSS

Laboratório de Monitoramento
e Manutenção Inteligente
de Sistemas e Estruturas



PyMLDA

Machine Learning for Damage Assessment

Monitoramento de Sistemas Dinâmicos - Apresentação Técnica

Marcela Machado | Jefferson Coelho



Monitoramento

Leitura contínua de sistemas
dinâmicos e sinais estruturais.



Machine Learning

Modelos para análise e apoio à
avaliação de dano.




Análise Técnica

Visualização clara de indicadores,
figuras e resultados.



Motivação e Benefícios

A **detecção precoce** de **danos** em sistemas dinâmicos **reduz custos** de manutenção, previne **falhas** catastróficas e **prolonga a vida útil** de infraestruturas críticas. O **monitoramento inteligente** baseado em IA **transforma** dados de dinâmicos em **diagnósticos acionáveis**.



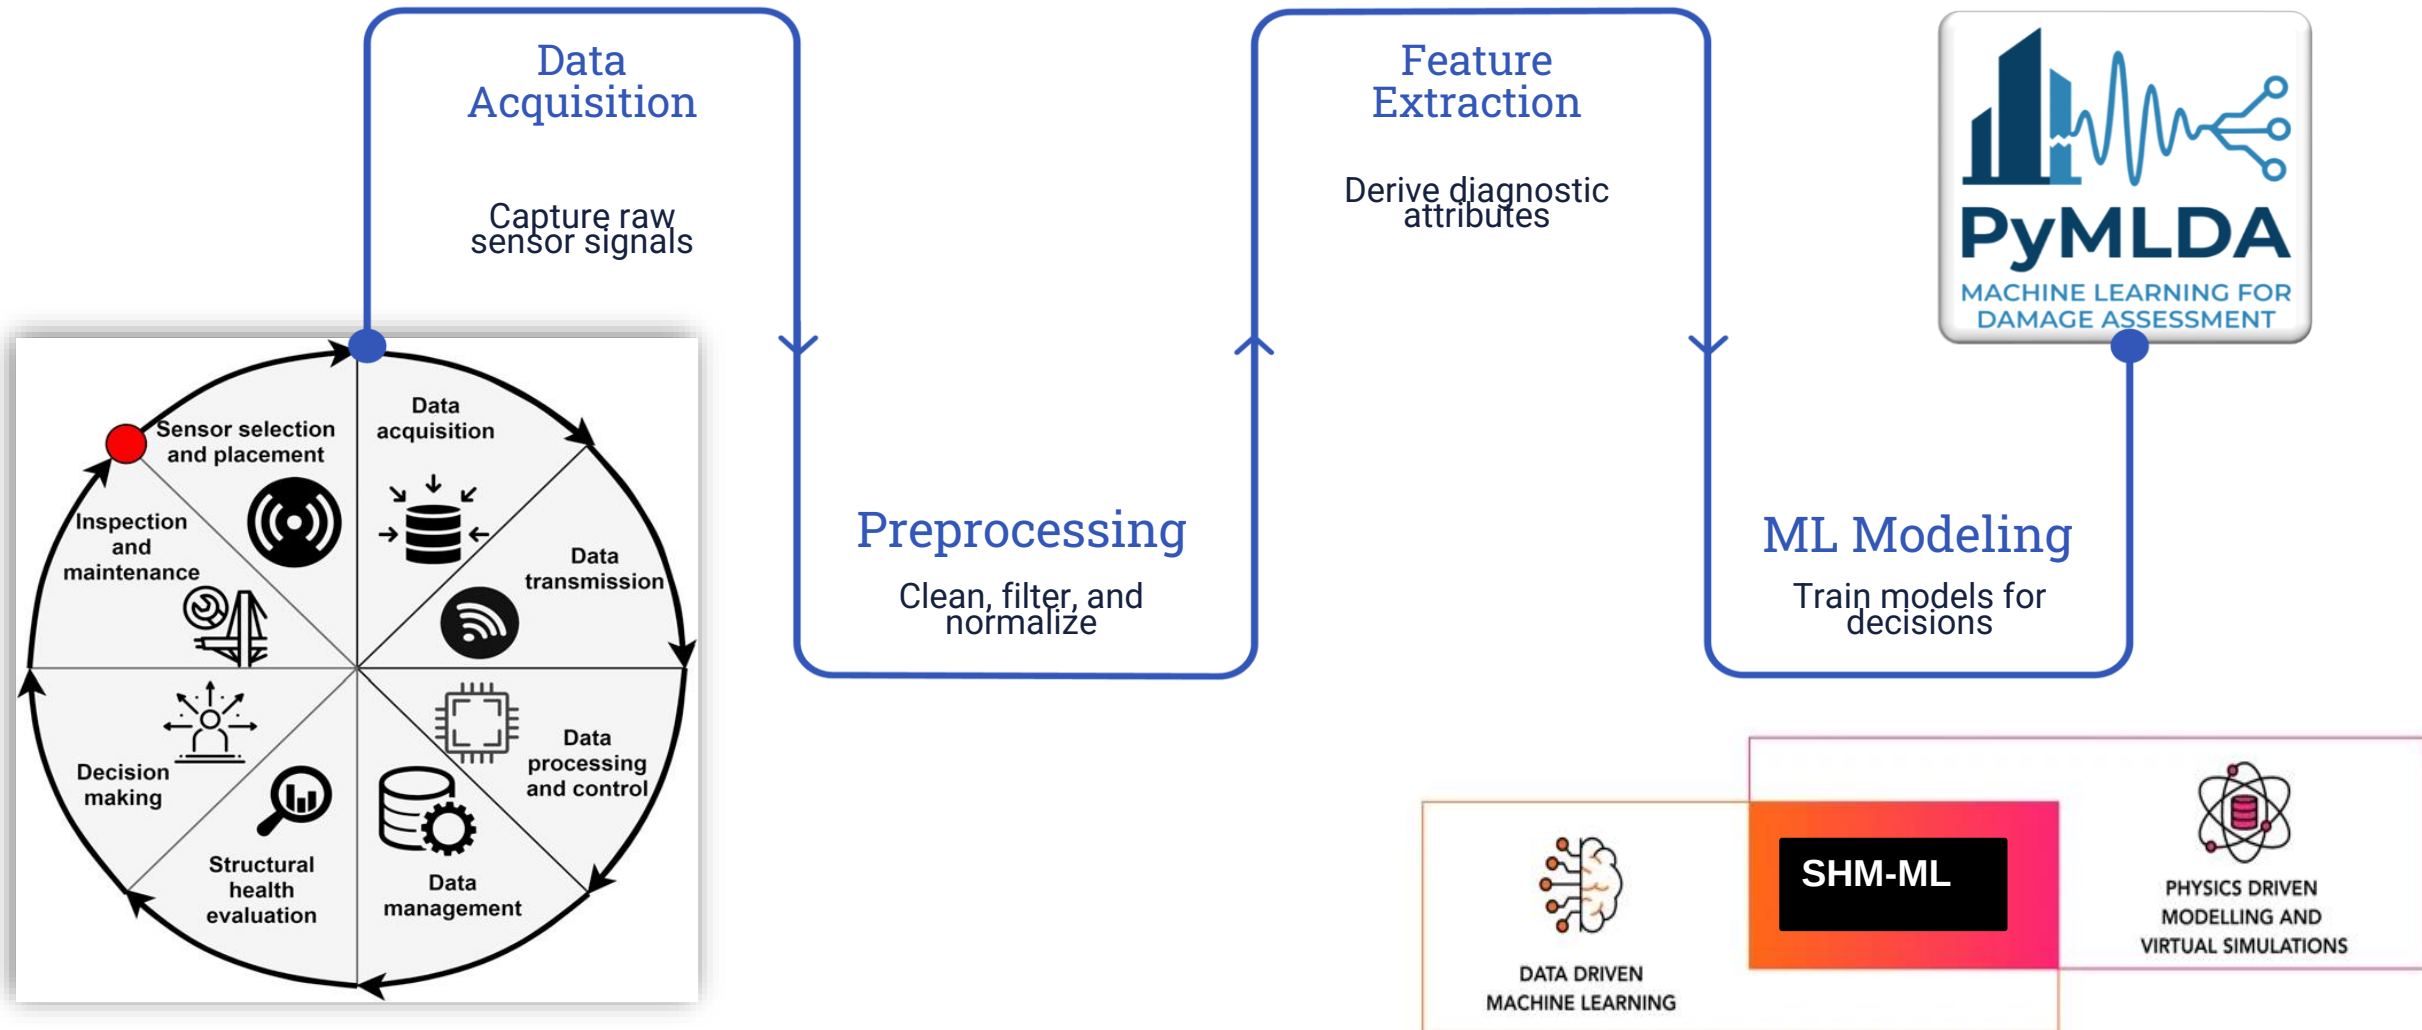
Hierarquia da Identificação de Danos

- O processo de monitoramento segue uma hierarquia bem definida: **detecção inicial até a avaliação completa da integridade estrutural**.
- Cada **nível exige maior complexidade** analítica e fornece informações mais precisas sobre o estado do sistema (*Malekloo et al., 2022; Rytter, 1993*).




Processo SHM-ML: Data Science Aplicado

O fluxo SHM-ML integra ciência de dados ao monitoramento estrutural, transformando sinais brutos de sensores em decisões de diagnóstico confiáveis por meio de aprendizado de máquina.



O que é o PyMLDA?

O **PyMLDA** (Python Machine Learning for Damage Assessment) é uma ferramenta open-source focada na detecção e quantificação de anomalias em sistemas estruturais utilizando inteligência artificial.



Turbinas e equipamentos industriais

Turbinas, geradores e ventiladores industriais



Infraestrutura civil

Pontes, pórticos, viadutos e barragens



Estruturas offshore

Estruturas offshore, tubulações e cascos



Máquinas rotativas

Máquinas rotativas e motores de indução

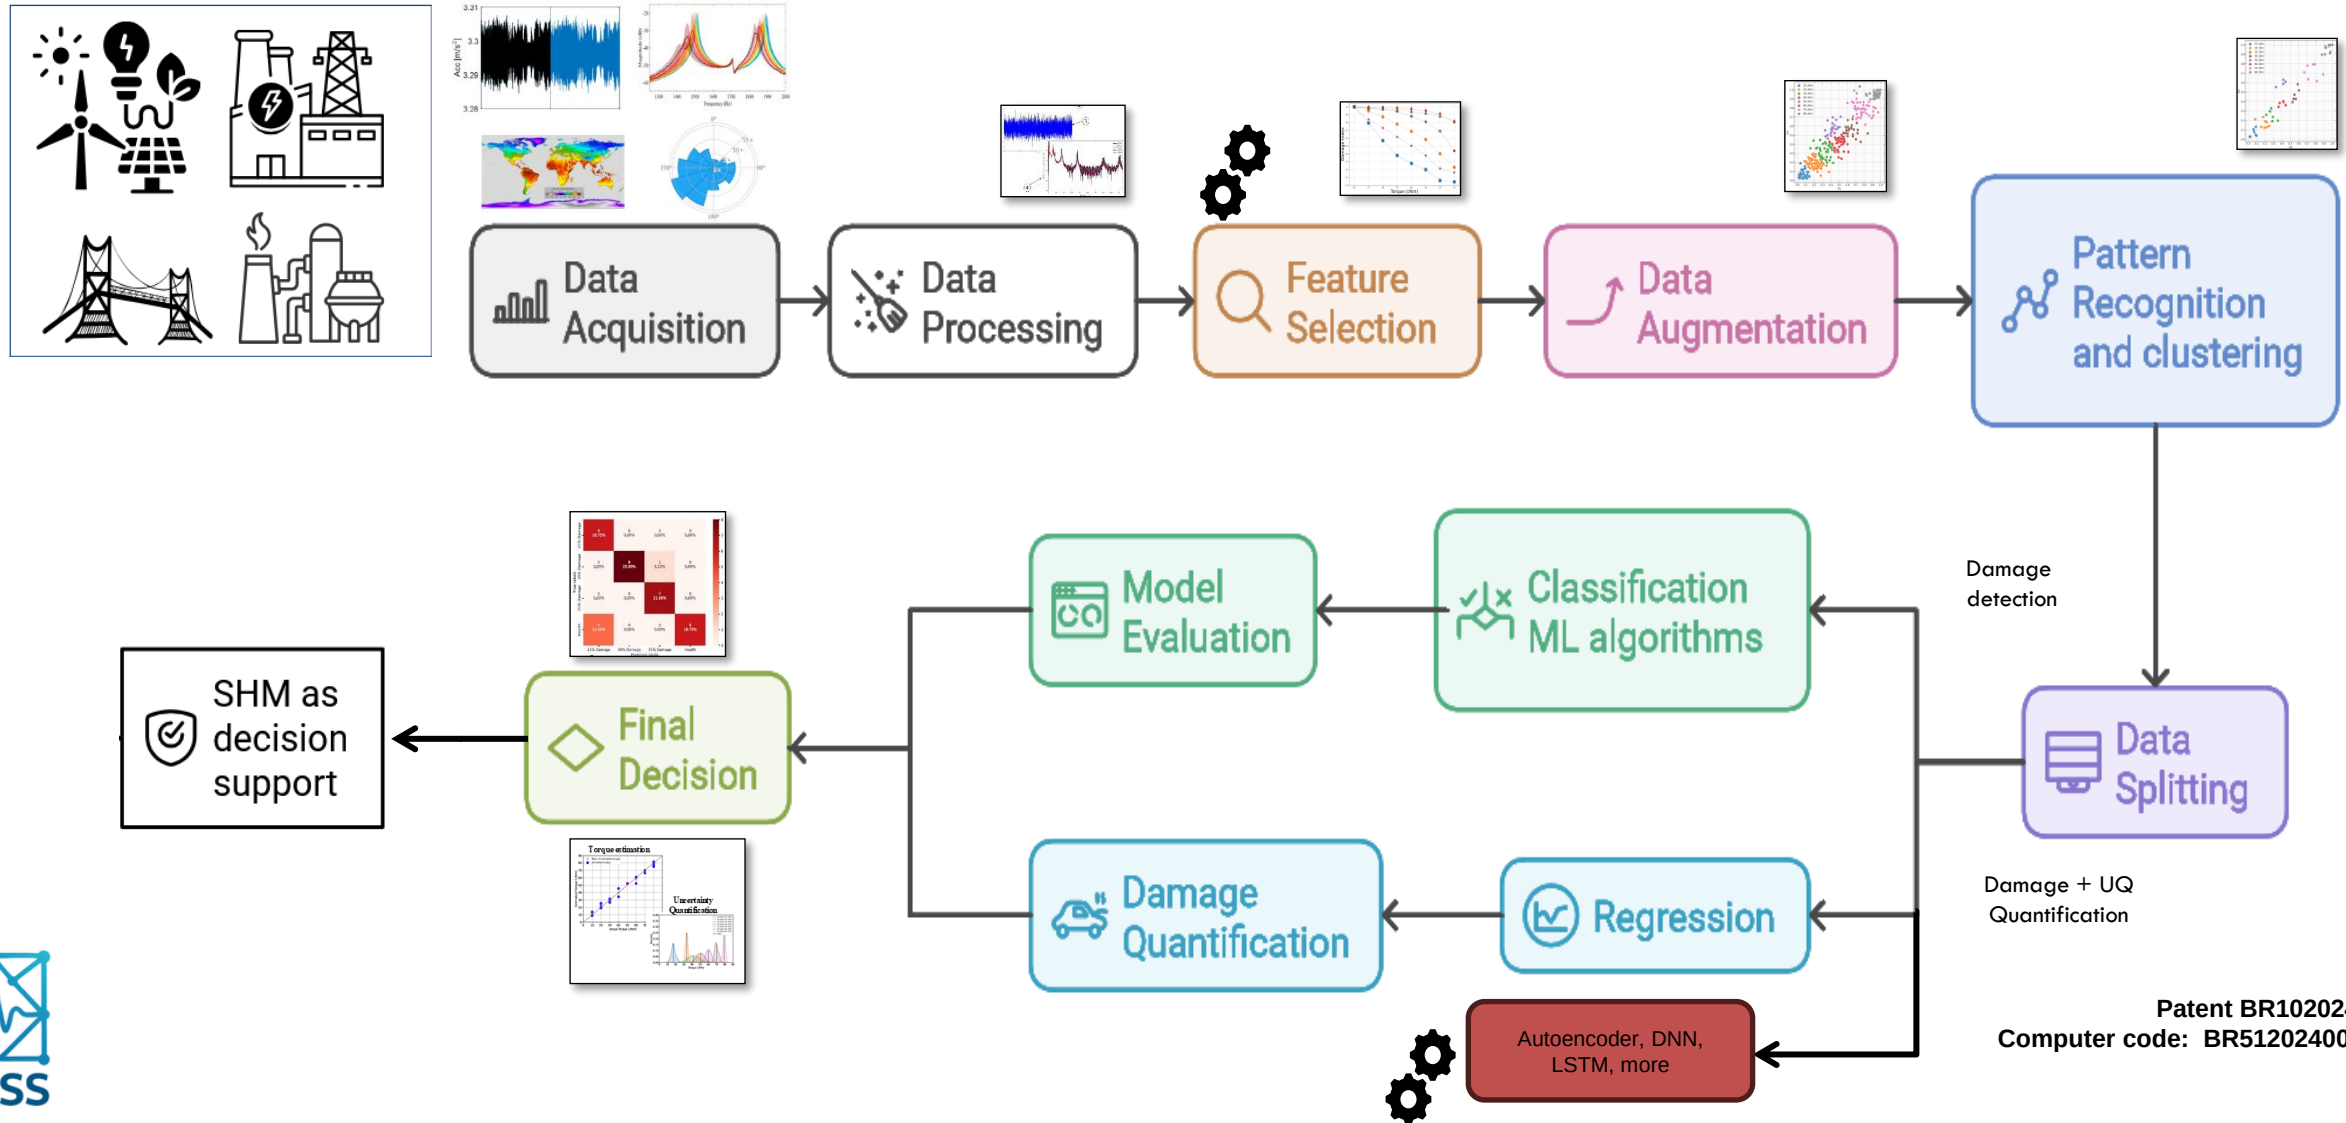


Processos Industriais

Processo de produção
Linha de produção

Arquitetura do PyMLDA

O MDLA integra múltiplos submódulos especializados, abrangendo desde a análise de dados até a validação cruzada robusta e **reprodutível**.



Patent BR10202401528
Computer code: BR512024001008-4

Pipeline de Monitoramento


O pipeline PyMLDA segue um **fluxo padronizado e reprodutível**, desde a **coleta de dados brutos** até o **diagnóstico final de danos**.

A **arquitetura é modular**, permitindo **substituição de componentes individuais sem afetar** o sistema como um todo.




Patente BR10202401528 ·

Código registrado: BR512024001008-4



Pipeline of the monitoring process



Módulos Principais

Submódulos especializados cobrem todo o fluxo de trabalho do pré-processamento à validação.

```
from pymla.features import extract_time_features


# Extração automática das métricas
feats = extract_time_features(signal)
print(f"RMS: {feats['rms']:.4f}")
print(f"Crest Factor: {feats['crest_factor']:.4f}")
```

Módulo	Funcionalidade
features/	Extração de features temporais, espectrais e FRF
datasets/	Construção automatizada de datasets
ml/models/	Fábrica de classificadores, clusterizadores e regressores
ml/evaluation/	Validação cruzada e métricas de avaliação
ml/preprocessing/	Balanceamento de classes e seleção de features
utils/	Visualizações e utilitários




📄 **Próximos passos:** Acesse o repositório [MOSS-vLab/pymla](#) para documentação completa e exemplos de uso.

Clustering dos Dados de SHM (K-Means, k=4)



Linear - Previsto vs Real
 $R^2 = 0.7092$



REGRESSÃO PARA QUANTIFICAÇÃO DE DANOS

Treino: 112 amostras
Teste: 28 amostras

Treinando modelos de regressão...

✓ Random Forest:
 R^2 : 0.6951
MSE: 0.000387
MAE: 0.014851

✓ SVR:
 R^2 : -0.0080
MSE: 0.001280
MAE: 0.032736

✓ Linear:
 R^2 : 0.7092
MSE: 0.000369
MAE: 0.015570

MELHOR REGRESSOR: Linear
 R^2 : 0.7092

Treinando e avaliando classificadores...



✓ Random Forest:
Acurácia: 0.6429
F1-Score: 0.6429
Precision: 0.6429
Recall: 0.6429



✓ SVM:
Acurácia: 0.6429
F1-Score: 0.6429
Precision: 0.6429
Recall: 0.6429

✓ KNN:
Acurácia: 0.4643
F1-Score: 0.4643
Precision: 0.4643
Recall: 0.4643

✓ XGBoost:
Acurácia: 0.6071
F1-Score: 0.6071
Precision: 0.6071
Recall: 0.6071

MELHOR CLASSIFICADOR: Random Forest
Acurácia: 0.6429





Failure classification of wind turbine operational conditions







Aventa AV-7 ETH Zurich Research Wind Turbine 7kW

The ASCE-EMI Structural Health Monitoring for Wind Energy Challenge – WedoWind. Awarded team

Challenge goal: To detect three fault events with the highest possible accuracy. The fault events are:

1. Pitch drive failure
2. Aerodynamic imbalance
3. Icing event

18 m




<https://zenodo.org/records/8229750>


Results - Wind Turbine Vesta V66 1.6MW (WindTAK co Poland)

Manufacturer	Vestas
Model	V66/1650
Condition	Used
Rated power	1650 Kw
Tower height	67 m
Rotor diameter	66 m

- Success rate for Stage 1 testing: **how many periods of actual icing does the algorithm correctly label as icing?**
- Success rate for Stage 2 training: **percentage of actual icing periods correctly identified by the algorithm.**



Metrics Performance	SVM	KNN	NB	RF	DT
Cross-validation	97,83%	94,62%	95,73%	97,83%	96,78%
Accuracy	100,00%	97,56%	90,24%	95,12%	97,56%
Precision	100,00%	97,56%	90,24%	95,12%	97,56%
Recall	100,00%	97,56%	90,24%	95,12%	97,56%
F1-Score	100,00%	97,56%	90,24%	95,12%	97,56%



Failure classification of wind turbine operational conditions

PO.084

RAVE (Research at alpha ventus) offers its 10 years
of measurement data to support research in offshore wind power

Dr. Bernhard Lange, Maren Engelhardt

Fraunhofer Institute for Wind Energy Systems Technology IWES, Germany



The first German offshore wind farm alpha ventus


© Matthias Ibeler

Alpha ventus and RAVE

The first German offshore wind farm “alpha ventus” was built in 2009 as a test field for the development of offshore wind power. Twelve 5 MW wind turbines of two different types and with two different foundation concepts were erected under genuine offshore conditions.

The accompanying research initiative “Research at alpha ventus” (RAVE) comprises research, development and demonstration activities in a coordinated effort. A broad range of research questions in utilization of offshore wind power are investigated in the areas of e.g. support structures, technology monitoring, grid integration and impact on the environment. To date, more than 35 projects were conducted with about 120 million euros support from the German

Measurement Data



Measurement sensors at two wind turbines in alpha ventus

© 2020 Fraunhofer IWES

Referências e Repositório do Projeto

Código e Documentação

- **GitHub Oficial:** github.com/MOSS-vLab/pymlda
- **Documentação Online:** pymlda.readthedocs.io
- **Licença de Distribuição:** Código livre para usos acadêmicos sob licença MIT.



OPEN-SOURCE

PYTHON


MOSS-VLAB

```
pip install git+https://github.com/MOSS-vLab/pymlda.git
```

BASH

Requisitos base: Python $\geq$ 3.7, NumPy, Pandas, Scikit-Learn.

Demonstração do PyMLDA




Artigo Científico Associado

Coelho et al. (2024). PyMLDA: A Python open-source code for Machine Learning Damage Assessment.
Software Impacts, Vol. 19, 100628.



Exemplo de aplicação

- Viga física reforçada com massa composta.
- Neste caso o dano/ anomalia é considerado pela perda de massa devido a remoção dos reforços da viga.
- A identificação, quantificação e prognóstico é realizada na perda de massa dos reforços da estrutura.




Dados Utilizados – open data

- **Features:** DI-1 e DI-2 (Índices de Dano)
- **Target (Classificação):** Categorias de dano (Healthy, 2,96% Damage, 5,92% Damage, 8,87% Damage)
- **Target (Regressão):** Mass loss [%] (Perda de massa)

<https://github.com/MOSS-vLab/Teaching-material/tree/main/OpenSD2026>



Tutorial PyMLDA





MoSS

Smart Monitoring and Maintenance
of Systems and Structures

Agradecemos muito pela atenção



github.com/MOSS-vLab/pymla



moss.vlab@gmail.com